Centro Universitário de Excelência
Sistemas de Informação

Tunando o Meu Modelo

Autores:
Joaqson Rodrigues Miranda
Lucas Santos Oliveira
Manoel Souza Santos
Monique Prado Pereira Gomes
Raian Rocha Santos

Vitória da Conquista, 2026

Agenda

O objetivo é comparar modelos de previsão e medir o ganho do ajuste de hiperparâmetros sobre o baseline.

1. Contexto e Cenário
Empresa, cenário e série temporal

2. Dados e Preparação
Séries temporais e divisão treino/teste

3. Modelos Iniciais
Random Forest × Gradient Boosting

4. Ajuste de hiperparâmetros
Grid Search × Random Search

5. Resultado final
Modelo tunado × baseline

Contexto e cenário

- MecâniQA atende oficinas e auto centers em Feira de Santana e região
- Problema: prever a demanda diária de manutenções para evitar prejuízos
- Baseline (média móvel) é o piso; a meta é superá-lo com Machine Learning

731 dias
registros diários no dataset

2 séries
trocas de óleo e manutenção de motor

2024–2025
período da série temporal

Dados e preparação

- Do dado bruto ao treino:
  - Séries analisadas: Trocas de Óleo e Manutenção do Motor.
  - Preparação: lags, médias móveis com shift(1) e calendário.
  - Divisão temporal: 80% treino e 20% teste, sem embaralhamento.

731 → 203
dias no dataset → registros utilizáveis

Divisão cronológica 80/20



07/03/2024 a 07/09/2025

08/09/2025 a 12/12/2025

```
Treino: 162 registros | 2024-03-07 até 2025-09-07
Teste : 41 registros | 2025-09-08 até 2025-12-12
✓ Divisão temporal validada: treino ocorre antes do teste.
```

Modelos iniciais

- Random Forest e Gradient Boosting com parâmetros padrão.
- Avaliação das previsões pelo RMSE no conjunto de teste.
- Random Forest apresentou menor erro nas duas séries.

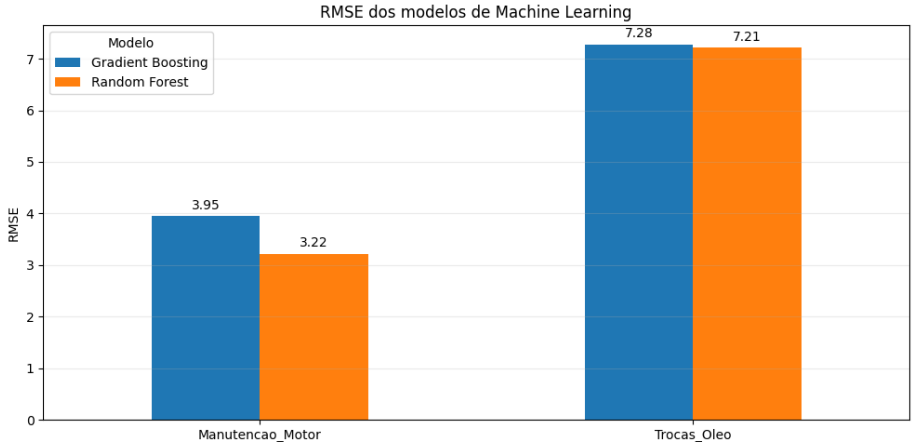


Figura 1 – Desempenho inicial dos modelos: menor RMSE indica maior precisão das previsões.

Ajuste por Grid Search

Como realizamos a otimização?

- Aplicamos GridSearchCV ao modelo Random Forest.
- Testamos quantidade de árvores, profundidade e divisão dos nós.
- Utilizamos TimeSeriesSplit para preservar a ordem temporal dos dados.

Melhores hiperparâmetros encontrados:

Série	n_estimators	max_depth	min_samples_split
Trocas de óleo	50	3	5
Manutenção de motor	100	3	2

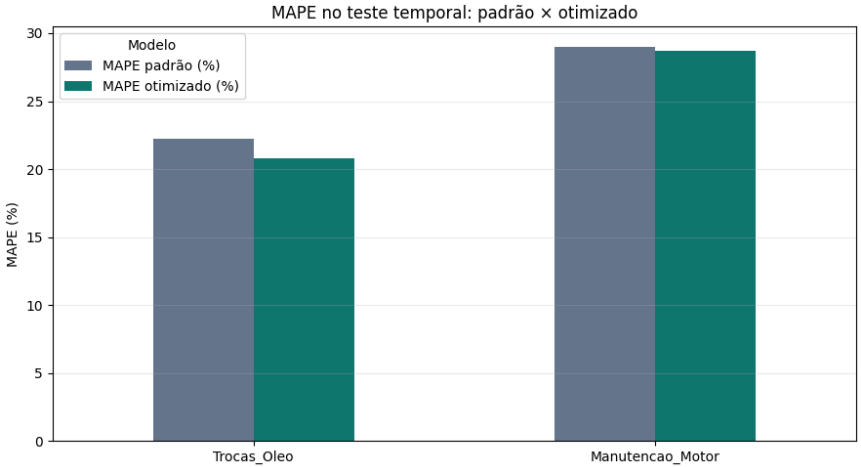


Figura 2 – Comparação do MAPE antes e após a otimização. Houve redução do erro percentual nas duas séries.

27 combinações avaliadas com validação temporal em 5 divisões.

Grid × Random Search

- Custo computacional × precisão:
  - Random Search avaliou 8 combinações de hiperparâmetros.
  - Redução de 85,46% no tempo de execução.
  - MAPE próximo ao Grid Search, com diferenças entre as séries.

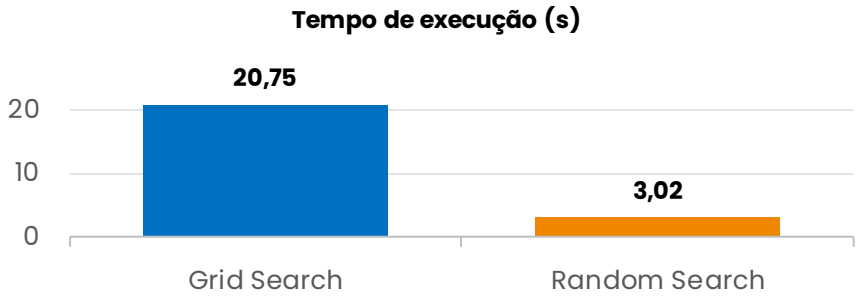


Figura 3 – Comparação do tempo de execução: Random Search apresentou redução de 85,46%.

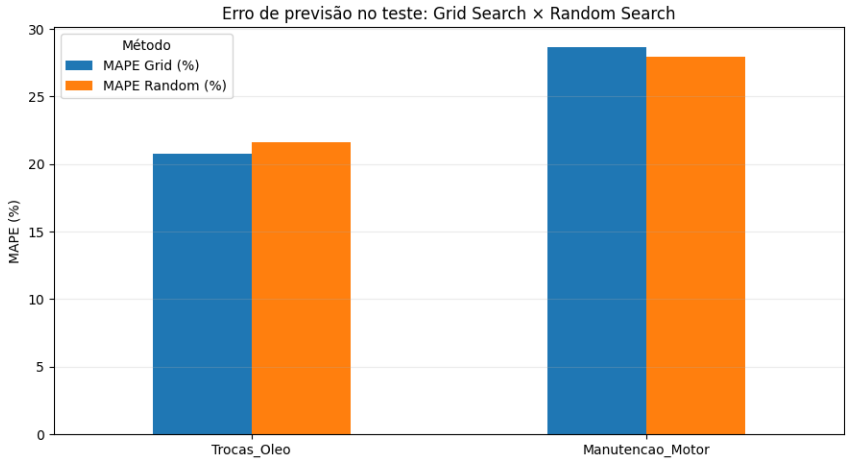


Figura 4 – Comparação do MAPE: resultados próximos, com vantagens diferentes por série.

Considerações finais

- Trocas de óleo: redução de 30,5% no erro médio.
- Manutenção do motor: redução de 33,06% no erro médio.
- Resultado: Random Forest tunado superou o baseline nas três métricas.

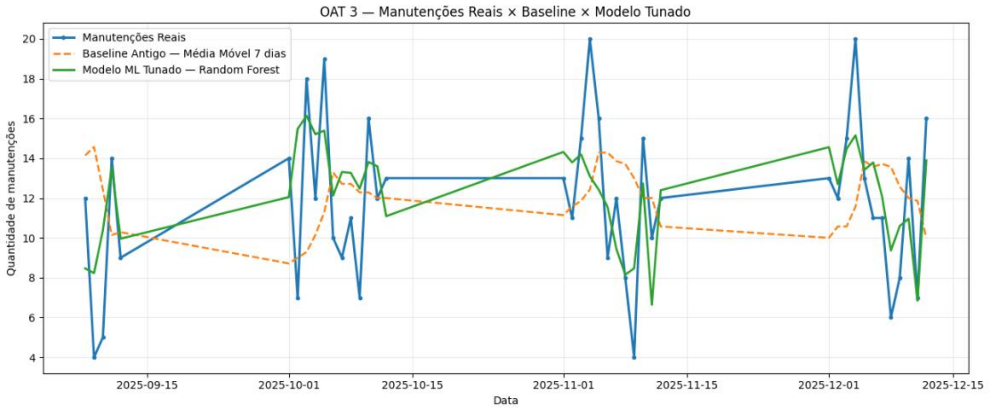


Figura 5 – Comparação entre demanda real, média móvel de 7 dias e previsão do Random Forest otimizado.

Comparação final de desempenho no conjunto de teste						
Cenário	**Trocas de óleo**			**Manutenção de motor**		
	MAE	**RMSE**	**MAPE %**	**MAE**	**RMSE**	**MAPE %**
Baseline (MM7)	8,45	10,31	31,86	3,93	4,74	44,31
ML inicial	6,08	7,21	22,22	2,63	3,22	29,03
ML tunado	**5,87**	**7,10**	**20,77**	**2,63**	**3,20**	**28,78**

Referências

- Caderno de Guias – OAT 3 – Tutoriais
- OAT 3: Tunando o Meu Modelo
- MecâniQA Dataset (série temporal utilizada)
- Repositório GitHub da equipe (branch main)